

论文复现：AdaBoost（假） —C-H吉布斯自由能预测—小数据量（劣）

- 一、研究目标
- 二、数据预处理
- 三、模型与训练方法
- 四、运行结果
- 五、问题

论文复现：AdaBoost（假） —C-H吉布斯自由能预测—小数据量（劣）

一、研究目标

使用人工神经网络（ANN），根据反应物及自由基相关特征，预测与 sp3 C-H 活化相关的氢原子转移（HAT）反应 Gibbs 活化能。密度泛函理论计算（UoB97X-D）用于建立甲氧基（CH₃O）、三氟乙氧基（CF₃CH₂O）、叔丁氧基（tBuO）和枯基氧基（CumO）自由基的反应体系数据集。

论文名：Rapid and Accurate Estimation of Activation Free Energy in Hydrogen Atom Transfer-Based C-H Activation Reactions : From Empirical Model to Artificial Neural Networks

二、数据预处理

数据集包含 7 个输入特征：BDFE_cat、BDFE_sub、x_cat、x_sub、d、Vbur_cat、Vbur_sub；预测目标为 gibbs。

```
###底物(substrate) 自由基(Free radical)

BDFE_cat (缩写错误: BDFE_rad) #自由基侧的键断裂自由能(H 提取自由基对应键的断裂自由能，反映反应自由基的热力学强度)
BDFE_sub#底物侧的键断裂自由能(被攻击的 C-H 键的断裂自由能)
x_cat#自由基侧的电负性 (x_rad)
x_sub#底物侧的电负性
d#不饱和性指示变量(邻近是否存在不饱和基团)(0表示饱和C-H,1 表示不饱和C-H)
Vbur_cat:#自由基侧埋藏体积(反映自由基在空间上对底物的拥挤程度)(Vbur_rad)
Vbur_sub:#底物侧埋藏体积(表示底物侧的空间位阻特征)
gibbs#反应的能垒
```

```
1 x_cat,x_sub,BDFE_cat,BDFE_sub,d,Vbur_cat,Vbur_sub,gibbs
2 6.899690543,4.803156459,92.82504426,95.96205768,0,22.5,14.1,18.81839739
3 6.899690543,3.870480283,92.82504426,90.48365887,0,22.5,16.8,16.17595278
```

数据文件	样本数	用途
train.csv	238	训练模型
test.csv	60	留出数据评估
selectivity.csv	15	选择性相关的额外评估

数据文件	样本数	用途
cumoexp.csv	45	CumO 实验对照数据评估

项目还提供了自由基、反应物/加氢产物及过渡态的 XYZ 坐标文件。不过当前程序不读取 XYZ，也没有包含从坐标和 DFT 计算结果生成 CSV 特征脚本。

#数据处理流程


特征矩阵P[特征数，样本数]与目标矩阵Y（Gibbs）[样本数，]导入 -> 将P和Y规定成二维向量 -> 最大绝对值归一化

最大绝对值归一化：（将7种特征值限制在0~1，防止某一种数据大的特征值主导梯度）

$$x' = \frac{x}{\max(|x|)}$$


三、模型与训练方法

手写的全连接前馈神经网络



采用全连接前馈神经网络，结构为 [7, 6, 6, 6, 1]：7 个输入节点、3 个各含 6 个节点的隐藏层，以及 1 个线性输出节点。隐藏层使用 tanh 激活函数（引入非线性，控制输出范围在-1~1）。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$



当前网络结构没有循环连接。程序最多训练 500 次迭代，并在训练误差达到设定阈值时停止。

四、运行结果

在当前提供的数据上运行一次，得到以下指标：

- MAE（平均绝对误差）= “平均每次偏差几”
- RMSE（均方根误差）= “偏差有多离谱”
- R^2 = “模型解释了多少真实波动”

数据集	RMSE	MAE	R^2
训练集	0.6839	0.5470	0.9320
测试集（评估模型泛化能力）	0.9882	0.7911	0.8712
选择性数据（判断位点选择性，实际并未有分类，只是将不同位点的数据一同导入到测试集中，通过gibbs间接判断位点的选择性优劣）	1.1058	0.9207	0.7198
CumO 实验对照数据（外部实验验证）	0.8093	0.6555	0.6982

五、问题

1.数据定义：

- 特征定义不确定（函数缩写不清晰）
- 缺少结构到特征的映射
- 测试集里 60 条记录具有相同的 组合，可能是为了提高测试集预测率
- 数据量小，容易出现过拟合，迁移能力弱

2.数据处理：

和常见机器学习流程相比，它没有做这些（未表现在提供代码中）：

- 噪声检测
- 异常值过滤
- 缺失值填充（提供的小型数据集里没有缺失值填充）
- 训练集/测试集切分（训练集和测试集数据来自不同的自由基体系）

3.模型训练：

- 扩展性差，归一化处理不严谨，没有成熟的自动微分、优化器封装、验证工具、早停机制，小规模数据
 - 模型不是严格的化学物理建模，而更像经验回归
 - 代码与实际论文中描述的模型不符，不是AdaBoost
-